Business Intelligence

Proyecto final · Entrega 1

Diagnóstico, estrategia y diseño

Diseño de la Solución de Business Intelligence para Supermercados Alianza Colombia S.A.

Integrante	Código
Ángel Nicolas Ayala Ríos	506232067
Danna Valentina Galvis Sánchez	506232745
Yefry Esteban Ávila Zuluaga	506232728

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	*23/10/2026*
Repositorio	https://github.com/valentinagalvis/bi-proyecto-equipo506232745

Resumen de la entrega

Este proyecto trata sobre el diagnóstico y diseño de una solución de Business Intelligence para Supermercados Alianza Colombia S.A., una cadena retail que tiene sedes en Bogotá, Medellín, Cali y Barranquilla. Hoy en día la empresa está en la Fase 1 (No existe BI) del modelo BIMM, básicamente porque tiene una arquitectura accidental, las fuentes de datos están desintegradas y hay bastantes problemas de calidad en la información. La idea con este proyecto es llevar a la organización hasta la Fase 4 (Data Warehouse), implementando un almacén de datos dimensional en estrella, con una granularidad centrada en cada ítem vendido por transacción POS en cada sede y fecha.

1. Caso de negocio

1.1 Organización y contexto

Supermercados Alianza Colombia S.A. es una empresa mediana del sector retail con operaciones en Colombia, y cuenta con cuatro sedes ubicadas en Bogotá, Medellín, Cali y Barranquilla. El decisor principal del caso es el Gerente Comercial y de Operaciones, quien actualmente toma las decisiones de abastecimiento, fijación de precios y asignación de promociones de manera empírica e intuitiva. Hoy en día la organización no cuenta con un sistema consolidado que le permita responder en tiempo real a preguntas clave de rentabilidad. La información comercial está fragmentada entre los puntos de venta

(POS) de cada sede, archivos planos que se consolidan manualmente y bases de datos heterogéneas. Esto impide calcular de forma ágil el margen de utilidad neta por categoría de producto, comparar el desempeño financiero entre ciudades o identificar patrones de pérdida en periodos de alta demanda.

1.2 Síntomas de arquitectura accidental

#	Síntoma	Evidencia en el caso	Capa afectada
S1	Inconsistencia de formatos y estándares entre sedes	La sede de Bogotá registra las transacciones POS con fechas en formato YYYY-MM-DD, mientras que la sede Cali las almacena en formato DD/MM/YYYY.	Fuentes / Integración
S2	Dispersión de fuentes de datos en múltiples formatos	Los registros de ventas operativas residen en archivos planos .csv, la información de catálogo de productos se mantiene en hojas de cálculo .xlsx, y los datos del programa de fidelización se exportan en formato. json.	Fuentes / Integración
S3	Ausencia de un repositorio centralizado de análisis	No existe una base de datos analítica o Data Warehouse. Los reportes mensuales se elaboran de forma manual mediante copiado y pegado de tablas en Excel, generando duplicidad de datos y demoras de hasta dos semanas para obtener reportes de ventas	Almacén de Datos

1.3 Preguntas de negocio

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
P0	¿Cuál es el margen de utilidad bruto por categoría de producto, ciudad y mes durante los últimos 2 años?	BI	Describe hechos históricos estructurados consolidados desde el almacén de datos dimensional.
P1	¿Cuáles son las 5 categorías de producto con mayor volumen de ventas totales y unidades vendidas en cada sede?	BI	Analiza transacciones pasadas agregadas por dimensión geográfica y producto.
P2	¿Qué porcentaje del total de las ventas mensuales proviene de clientes	BI	Mide el comportamiento de compra histórico de segmentos de clientes específicos.

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
	pertenecientes al programa de fidelización?		
P3	¿Qué sedes y categorías registran disminuciones recurrentes en el margen de ganancia durante los fines de semana?	BI	Identifica patrones operacionales comparando métricas agregadas en la dimensión tiempo y espacio.

2. Inventario de fuentes

2.1 Fuentes

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F1 — Ventas POS	Exportación del sistema POS interno	CSV	16.900 (16.605 válidos)	2023-01 a 2024-12	2026-10-20	Interna / uso académico
F2 — Catálogo de productos	Maestro de productos del ERP interno	XLSX	46 (40 productos)	Corte 2024	2026-10-20	Interna / uso académico
F3 — Programa de fidelización	Exportación del CRM de fidelización	JSON	2.025 (2.000 clientes)	Altas 2019-2024	2026-10-20	Interna / uso académico (Ley 1581/2012)
F4 — SIPSA Precios mayoristas (REAL)	https://www.datos.gov.co/dataset/Sistema-de-Informaci-n-de-Precios-y-Abastecimiento/gkqq-k3k5	XLSX (CSV/JSON/API)	281.386	2013-01 a 2017-12	2026-10-23	CC BY-SA 4.0 (DANE)

2.2 Problemas de calidad detectados

Fuente	Campo	Problema	Ejemplo real del dato
F1	fecha	Fechas como texto en tres formatos mezclados (1.184 no ISO). Evidencia del síntoma S1.	«21/12/2024» junto a «2024-03-15»

Fuente	Campo	Problema	Ejemplo real del dato
F2	id_producto	SKU duplicados que rompen la unicidad de la llave (6 casos).	«P0021» aparece dos veces
F3	activo	Booleano con 9 representaciones distintas para el mismo dato.	«Sí», «si», «1», «true», «no», «0», «N»
F4	Precio	Precio como texto con símbolo de moneda y separadores (17.762 casos).	«$ 9.967», «9.833,00»

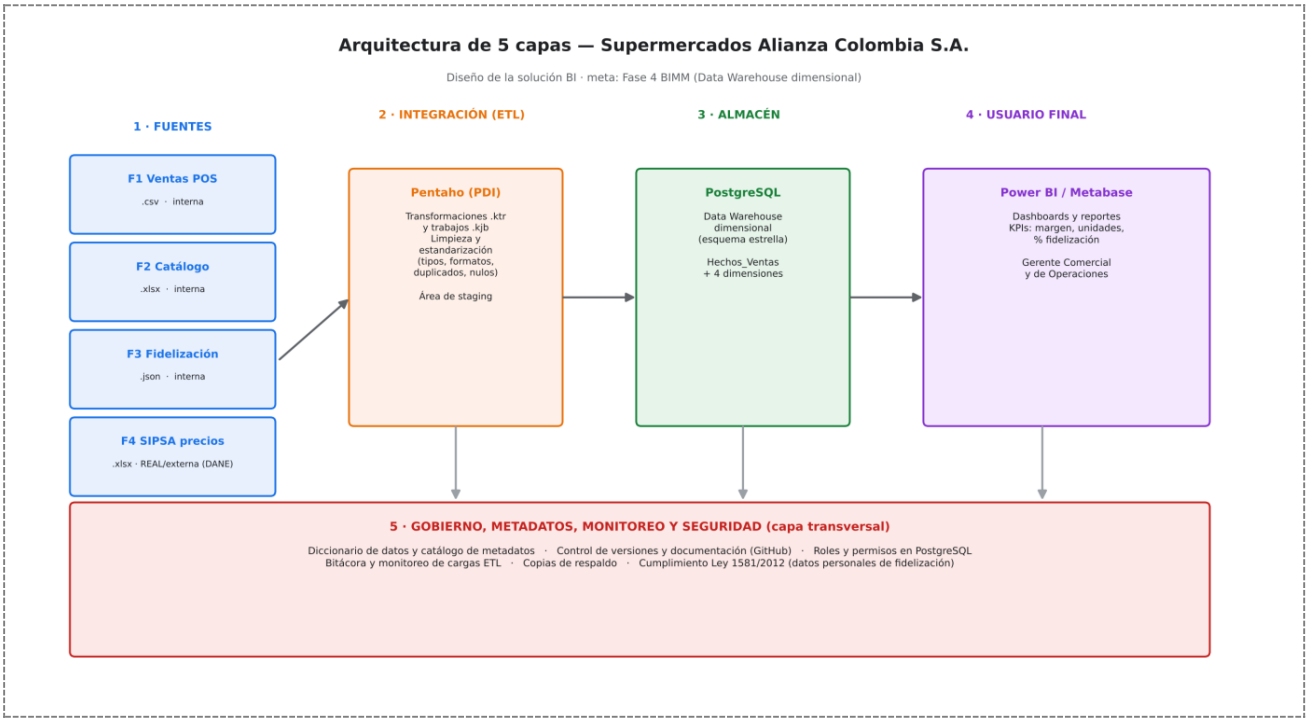
3. Diagnóstico de madurez

Elemento	Respuesta
Fase actual	Fase 1 — No existe BI.
Evidencia	S1 (formatos inconsistentes entre sedes), S2 (dispersión de fuentes en .csv/.xlsx/.json) y S3 (sin repositorio analítico; reportes manuales por copiar/pegar).
Por qué no es la fase siguiente	Para estar en la Fase 2 (Datos accesibles sin BI) se necesitarían datos integrados y disponibles para consulta desde un punto común. Hoy los datos existen, pero están fragmentados y solo se consolidan manualmente (con duplicidad y demoras de hasta dos semanas); no hay integración ni una capa de acceso compartida.
Fase objetivo al final del proyecto	Fase 4 — Data Warehouse.
Brechas que cierra el proyecto	▪ La capa de Integración/ETL (4.2) cierra la inconsistencia de formatos y la dispersión de fuentes (S1, S2). ▪ El Data Warehouse dimensional (4.2) cierra la ausencia de repositorio analítico (S3). ▪ La capa de Usuario final (4.2) cierra la elaboración manual de reportes. ▪ La capa de Gobierno y metadatos (4.2) cierra la falta de estándares y trazabilidad.

4. Arquitectura

La arquitectura propuesta sigue un flujo de cinco capas: las cuatro fuentes se extraen y estandarizan en una capa de integración con Pentaho Data Integration, se cargan en un Data Warehouse dimensional en PostgreSQL y se consumen desde una capa de usuario final. Una capa transversal de gobierno, metadatos, monitoreo y seguridad acompaña todo el flujo.

4.1 Diagrama de cinco capas del caso



4.2 Componentes por capa

Capa	Componentes y herramientas del caso	Función en el caso
1. Fuentes de datos	F1 Ventas POS, F2 Catálogo, F3 Fidelización, F4 SIPSA	Proveen ventas, catálogo y costos, clientes fidelizados y precios mayoristas de referencia.
2. Integración (ETL)	Pentaho Data Integration: transformaciones y trabajos; área de staging; cargas programadas	Extrae, limpia y estandariza tipos y formatos, elimina duplicados y resuelve nulos de las cuatro fuentes.
3. Almacén de datos	PostgreSQL con modelo dimensional en estrella	Repositorio analítico único, histórico y consultable.
4. Usuario final	Power BI Desktop	Dashboards y reportes de margen, unidades y fidelización para el Gerente Comercial y de Operaciones.
5. Gobierno, metadatos, monitoreo y seguridad	Diccionario de datos; GitHub; roles y permisos en PostgreSQL; bitácora y monitoreo de ETL; backups	Estándares, trazabilidad, seguridad y cumplimiento de la Ley 1581/2012.

4.3 Marco de Referencia de cuatro categorías

Categoría	Decisión tomada	Justificación
Arquitectura de información	Responder P0–P3 con los KPIs margen bruto, unidades vendidas y % de fidelizados, sobre un modelo conceptual centrado en la venta.	Alinea la solución con las decisiones del Gerente Comercial y de Operaciones.
Arquitectura de datos	Fuentes identificadas → ETL en Pentaho (PDI) → DW dimensional en estrella con grano de línea de venta.	El esquema estrella optimiza las consultas analíticas y es trazable a las preguntas.
Arquitectura técnica	PostgreSQL (DW), Pentaho Data Integration (ETL), Power BI/Metabase (BI), GitHub; despliegue en cloud IaaS.	Herramientas gratuitas/open-source acordes con el presupuesto ajustado.
Arquitectura de producto	Tableros interactivos y reportes por categoría, ciudad, mes y segmento de cliente.	Entrega respuestas ágiles que hoy tardan hasta dos semanas.

4.4 Decisión de despliegue

Criterio	On-premise	Opción cloud: IaaS (VM en la nube)	Elegida y por qué
Costo	Alta inversión inicial en servidores (CAPEX).	Pago por uso, sin CAPEX; se escala o apaga según demanda.	IaaS: evita inversión inicial; mejor para presupuesto ajustado.
Seguridad y cumplimiento	Control físico total, pero toda la responsabilidad recae en un equipo pequeño.	Responsabilidad compartida; cifrado y backups gestionados.	IaaS: más seguridad gestionada (Ley 1581).
Escalabilidad	Limitada por el hardware; ampliar exige comprar equipos.	Escalado vertical y horizontal bajo demanda.	IaaS: crece con el negocio.
Acceso móvil	Requiere VPN o exponer servicios manualmente.	Acceso web y móvil nativo desde las 4 sedes.	IaaS: acceso distribuido inmediato.

5. Modelo dimensional

Se elige un modelo dimensional en estrella centrado en el proceso de venta POS, por su simplicidad de consulta y su trazabilidad directa con las preguntas de negocio.

5.1 Proceso de negocio

El proceso modelado es la venta en punto de venta (POS): cada vez que un cliente compra uno o más productos en una sede, el sistema POS registra las líneas de la transacción (producto, cantidad, precio y, si aplica, cliente fidelizado). Este evento es el núcleo de los ingresos y del margen de la cadena.

5.2 Granularidad

Una fila de la tabla de hechos representa **una línea de producto (un ítem) dentro de una transacción de venta POS, en una sede y en una fecha determinada.**

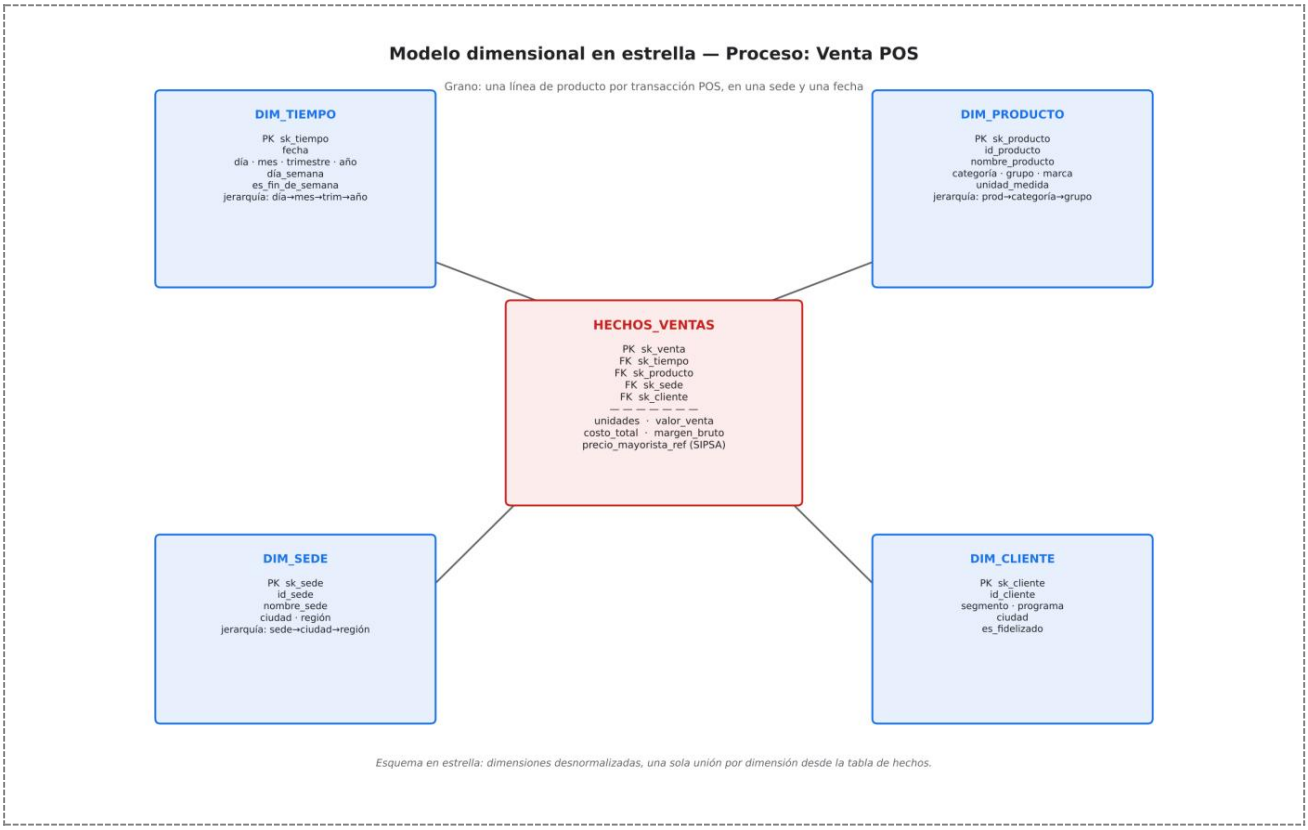
5.3 Métricas de la tabla de hechos

Métrica	Tipo de dato	Aditividad	Origen o fórmula
unidades	Entero	Aditiva	F1 — unidades vendidas en la línea.
valor_venta	Decimal	Aditiva	F1 — precio_unitario ×unidades.
costo_total	Decimal	Aditiva	F1/F2 — costo_unitario ×unidades.
margen_bruto	Decimal	Aditiva	valor_venta − costo_total.
precio_mayorista_ref	Decimal	No aditiva	F4 SIPSA — precio mayorista por producto-ciudad-mes.

5.4 Dimensiones

Dimensión	Atributos principales	Jerarquía	Fuente
Tiempo	*fecha, mes, trimestre, año*	*día → mes → trimestre → año*	*Generada*
Producto	id_producto, nombre, categoría, grupo, marca, unidad_medida	producto → categoría → grupo	F2 Catálogo
Sede	id_sede, nombre_sede, ciudad, región	sede → ciudad → región	F1 / maestro de sedes
Cliente	id_cliente, segmento, programa, ciudad, es_fidelizado	segmento (sin jerarquía profunda)	F3 Fidelización

5.5 Diagrama del esquema



Se elige estrella porque privilegia el desempeño de consulta y la legibilidad para el decisor: las dimensiones quedan desnormalizadas, de modo que cada pregunta se resuelve con una sola unión entre la tabla de hechos y cada dimensión, en lugar de los múltiples joins que impondría el copo de nieve. Como las jerarquías son estables y poco profundas y el volumen es moderado, la redundancia controlada del estrella no genera problemas de mantenimiento y sí facilita el modelado en Power BI/Metabase.

5.6 Trazabilidad con las preguntas

Pregunta	Métricas que usa	Dimensiones que usa
P0	margen_bruto, valor_venta, costo_total	Producto (categoría), Sede (ciudad), Tiempo (mes, año)
P1	valor_venta, unidades	Producto (categoría), Sede (sede)
P2	valor_venta	Cliente (es_fidelizado), Tiempo (mes)
P3	margen_bruto	Sede, Producto (categoría), Tiempo (es_fin_de_semana)

6. Referencias

Casters, M., Bouman, R., & van Dongen, J. (2010). Pentaho Kettle solutions: Building open source ETL solutions with Pentaho Data Integration. Wiley.

Congreso de la República de Colombia. (2012). Ley 1581 de 2012: por la cual se dictan disposiciones generales para la protección de datos personales. Diario Oficial No. 48.587. http://www.secretariasenado.gov.co/senado/basedoc/ley_1581_2012.html

Departamento Administrativo Nacional de Estadística [DANE]. (2025). Sistema de Información de Precios y Abastecimiento del Sector Agropecuario (SIPSA), Componente de Precios Mayoristas 2013–2024 [Conjunto de datos]. Portal Nacional de Datos Abiertos de Colombia. https://www.datos.gov.co/dataset/Sistema-de-Informaci-n-de-Precios-y-Abastecimiento/gkqq-k3k5

Eckerson, W. W. (2007). Beyond the basics: Accelerating BI maturity. The Data Warehousing Institute (TDWI).

Inmon, W. H. (2005). Building the data warehouse (4.ª ed.). Wiley.

Kimball, R., & Ross, M. (2013). The data warehouse toolkit: The definitive guide to dimensional modeling (3.ª ed.). Wiley.

The PostgreSQL Global Development Group. (2024). PostgreSQL 16 documentation. https://www.postgresql.org/docs/

Anexos

Anexo A. Diccionarios de datos

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
F1 — Ventas POS (.csv)				
id_venta	Texto	Identificador único de la transacción POS (PK natural)	V0000123	—
fecha	Fecha	Fecha de la venta (grano diario)	2024-03-15	Tipo texto en 3 formatos mezclados (2024-03-15, 15/03/2024, 15-mar-24)
id_sede	Texto	Código de la sede/almacén	S01	—
ciudad	Texto	Ciudad de la sede	Bogotá	Mayúsculas/minúsculas inconsistentes (bogotá)
id_producto	Texto	FK al catálogo de productos	P0007	—
categoria	Texto	Categoría del producto (redundante con catálogo)	CARNES	24 variantes por may/min y espacios (frutas, ' PESCADOS ')
unidades	Entero	Unidades vendidas	4	Valores negativos por devoluciones mal registradas (-3); a veces texto
precio_unitario	Decimal	Precio de venta unitario (COP)	20640	Texto con moneda/separador ($ 20.640); nulos (dato faltante)
costo_unitario	Decimal	Costo unitario de la mercancía (COP)	13796	Texto con separador decimal coma (13.796,00)
id_cliente	Texto	FK al cliente fidelizado; vacío si venta anónima	C00482	Vacío legítimo (no fidelizado) ≠ nulo por error
canal	Texto	Canal de venta	Tienda física / App / Domicilio	—
F2 — Catálogo de productos (.xlsx)				
id_producto	Texto	Identificador del producto / SKU (PK)	P0007	SKU duplicados (P0021 aparece 2 veces)
nombre_producto	Texto	Nombre comercial del producto	Pechuga de pollo	Espacios sobrantes ('Lenteja 500g ')

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
categoria	Texto	Categoría comercial	CARNES	15 variantes por may/min y espacios (procesados)
grupo	Texto	Grupo de alimento (alineado a SIPSA)	CARNES	—
marca	Texto	Marca del producto	Alpina	Valores nulos (6 registros sin marca)
unidad_medida	Texto	Unidad de venta	kg / und / lb	—
costo_referencia	Decimal	Costo de reposición de referencia (COP)	13796	Texto con moneda/separador (2.218,00)
F3 — Programa de fidelización (.json)				
id_cliente	Texto	Identificador del cliente (PK)	C00482	IDs duplicados (25 registros repetidos)
nombre	Texto	Nombre del titular	Camila Gómez	—
ciudad	Texto	Ciudad de residencia	Medellín	Mayúsculas/minúsculas inconsistentes (medellín)
segmento	Texto	Nivel del programa	Clásico / Plata / Oro / Platino	Valores nulos (133 registros)
email	Texto	Correo de contacto	camila12@correo.com	Correos sin '@' (isabela781correo.com)
telefono	Texto	Teléfono de contacto	3001234567	Formatos inconsistentes ('(57) 3961685926', truncados)
fecha_inscripcion	Fecha	Fecha de alta en el programa	2022-05-10	Formatos mezclados (10/05/2022, 10-may-22)
activo	Booleano	Estado de la membresía	true	9 representaciones distintas (true/True/1/0/no/si/Sí/N/False)
puntos	Entero	Puntos acumulados	12500	A veces almacenado como texto
F4 — SIPSA Precios mayoristas (.xlsx, REAL)				
Fecha	Fecha	Mes de referencia (primer día del mes)	2016-07-01	Tipo texto en 3 formatos (2016-07-01, 01/07/2016, 01-jul-16)
Grupo	Texto	Grupo de alimento (8 categorías)	CARNES	24 variantes por may/min y espacios
Producto	Texto	Alimento monitoreado (376)	Alas de pollo con costillar	Espacios sobrantes y mayúsculas sostenidas
Fuente	Texto	Plaza mayorista (ciudad, central) — 97 plazas	Bogotá, D.C., Corabastos	May/min inconsistentes (bogotá, d.c., corabastos)

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
Precio	Decimal	Precio mayorista promedio mensual en COP (incluye IVA)	3073	Texto con moneda/separador ($ 9.967, 9.833,00)

Anexo B. Diagramas a tamaño completo

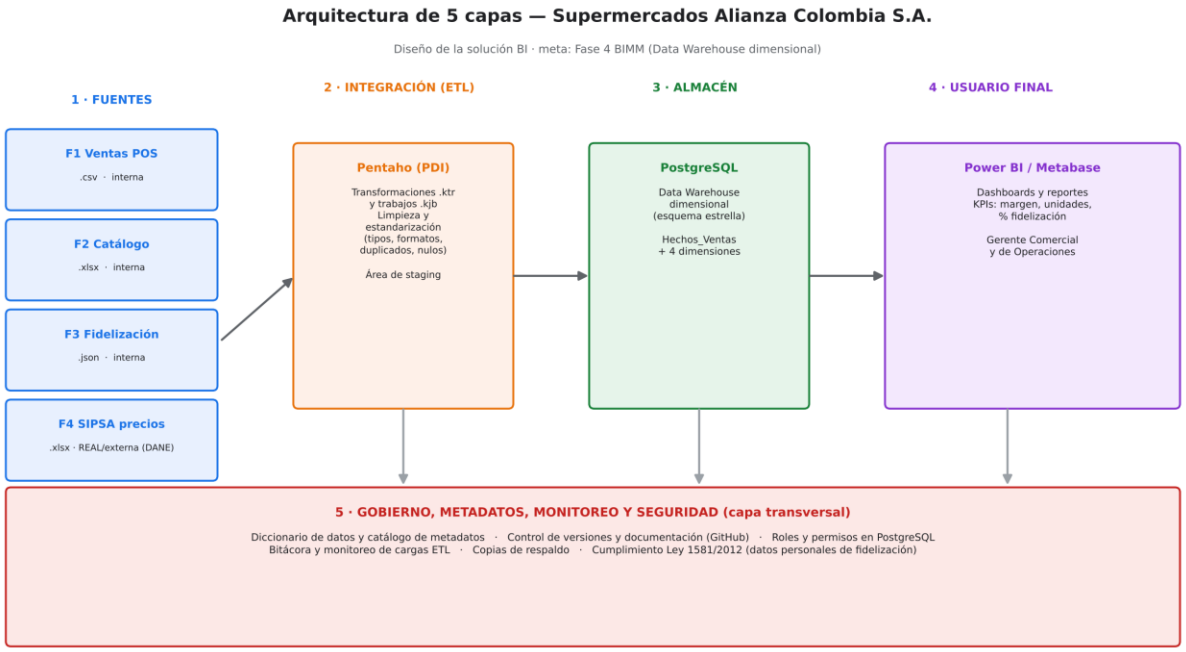


Figura B1. Arquitectura de cinco capas.

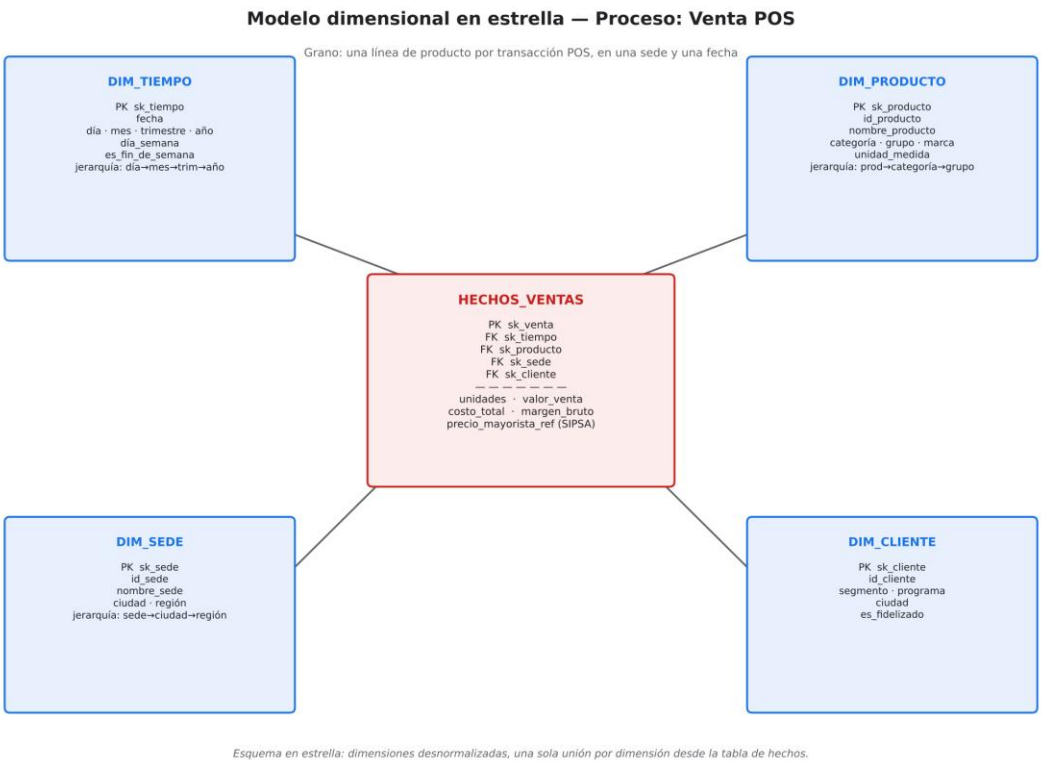


Figura B2. Esquema dimensional en estrella.